

附表 1:

东南大学校级 S RTP 项目中期检查表

院系名称:

项目名称	基于连续双帧射频指纹的 LoRa 设备识别技术研究				
项目编号	202509002	学生负责人	曹睿	指导教师	吴文甲

一、项目进展状况:

从 2024 年 10 月立项, 现已实施了 5 个月, 项目组已从射频指纹设备识别、LoRa 物理层信号预处理等方面做了充分地调研, 设计实现了 LoRa 信号数据的采集和预处理方案, 并初步构建了指纹识别模型。同时, 开展了相应的实验验证工作, 验证方案和模型的有效性。

1.1 设计实现了 LoRa 信号数据的采集和预处理方案

(1) 数据采集:

采用 USRP N210 作为信号接收设备, 使用 GNU Radio 进行原始 I/Q 射频信号采集。从中解析出 LoRa 帧的前导码、载波频偏 (CFO) 等信号数据, 并将这些信号数据以帧为单位进行存储。

(2) 数据预处理:

完成帧同步和 CFO 补偿, 这里采用均值瞬时频率估计进行粗 CFO 补偿; 采用自相关分析进行精 CFO 补偿, 减少温度等因素对 CFO 估计的影响, 以及归一化操作。

1.2 初步构建了指纹识别模型

本项目组完成基于相位差分特征的 LoRa 设备识别方法 (Diff-ADF)。利用连续双帧的指纹特性, 提取相位噪声和 CFO, 通过差分操作生成相位差分特征, 综合考虑相位差分特征和 CFO 对分类的影响, 再结合机器学习算法设计混合特征分类器, 从而实现设备识别。

设备识别方法 Diff-ADF 框架如图 1 所示:




图 1 Diff-ADF 框架

(1) 通过相位差分特征提取方法，从连续双帧信号中提取设备固有的相位噪声特征，消除指纹特征中受环境影响的部分，以增强指纹的抗干扰能力。




图 2 连续双帧的相位差分特征

(2) 结合 CFO 作为辅助特征，设计 混合特征分类器 Diff-ADF 进行设备身份识别。

(3) 采用最大最小归一化处理相位噪声，提高特征的区分度与稳定性。

(4) 采用均方误差 (MSE) 匹配策略 进行设备分类，确保模型对设备的精准识别。

1.3 实验验证

我们已完成 18 台型号为 RA01-SC、搭载 LLCC68 芯片的设备实验和测试工作。终端设备实物如图 3 所示：




图 3 本项目用到的 LoRa 设备

对 Diff-ADF 和模型基于深度学习的可扩展且信道鲁棒的无线射频指纹识别模型 (SC-RFFI) 进行对比分析，测试不同时间采集的数据对模型的影响。并评

估训练集和测试集在同一天/不同天的情况下，模型的分类准确率。




图 4 Diff-ADF 模型的射频指纹识别测试结果




图 5 SC-RFFI 模型的射频指纹识别测试结果

两种模型测试准确率比较结果如表 1 所示，不难发现 Diff-ADF 在相同环境下的识别准确率较高，表明其具有较好的区分能力。Diff-ADF 在不同天的数据集上仍然优于 SC-RFFI，说明本项目组的模型受设备位置、信道条件变化的影响更小。




图 6 两种模型的测试结果比较

二、项目存在问题及解决方案

2.1 模型完善优化方案

- (1) 问题描述：
- 当前射频指纹识别模型尚未完成对非视距（NLoS）环境、低信噪比（SNR）条件、信道动态特性以及连续帧操作特征提取方面的系统性评估与测试，并且仍存在着一定程度上的鲁棒性与准确性不足的问题。
- (2) 解决方案：
- 1) 数据采集优化方案
- 进行多环境、多场景数据扩充，在 LoS 与 NLoS 条件下进行充分的数据采集，特别注重不同材料障碍物（如混凝土墙、金属板、木质材料）对信号传播的影响。扩展信噪比范围测试（从 16 dB 降低至 5 dB），详细记录不同 SNR 条件下的识别准确率变化，提高模型在极端低信噪比条件下的鲁棒性。收集来自多个不同设备、多位置、多时间段的数据，避免模型过拟合于特定环境或特定设备。
- 2) 数据预处理优化方案
- 噪声抑制与多径效应补偿
- 使用自适应噪声抑制技术（如 Kalman 滤波）去除环境噪声，提高信号清晰度采用经验模态分解（EMD）和小波变换有效去除随机噪声，确保指纹特征的稳定性。通过拉格朗日插值技术校准多径效应引起的时延误差，进一步提高特征质量。

• 信道归一化与 CFO 校正

实施信道估计与均衡技术，有效消除信道条件变化对信号特征提取的影响。优化载波频率偏移（CFO）补偿方案，引入温度-频率漂移建模，实现更准确的补偿。采用傅里叶变换（FFT）实现精确的相位标准化和频率漂移校正。

3) 特征提取优化方案

• 扩展特征维度与时频分析

引入短时傅里叶变换（STFT）以提取更加丰富的动态时频特征，提升模型的分辨能力。利用 EMD 提取信号细节，提高信号特征的稳定性与辨识度。

• 探索更具有鲁棒性泛化性的特征

深度学习分析 LoRa 设备及其物理层信息，综合分析差分、拼接、相加等连续帧操作对识别效果的影响，通过消融实验确定最佳操作方式。

4) 模型结构优化方案

• 轻量级时序深度学习模型

结合 1D-CNN 与 GRU/LSTM 混合模型结构，捕捉信道动态特征变化，提高对环境变化的适应能力。增加注意力机制（Self-Attention），突出识别关键特征，进一步提升对微弱变化的敏感性。

• 度量学习强化泛化性

使用 Siamese Network 或 Triplet Loss 进行度量学习，强化模型对不同设备特征差异的区分能力，提升泛化性能。

2.2 实验规模扩大方案

(1) 问题描述:

目前我们已完成 18 台型号为 RA01-SC、搭载 LLCC68 芯片的设备的数据采集并进行实验，初步验证了系统架构的可行性以及关键算法的有效性。但是对于整个研究，设备数量和规模上尚不达标，模型仍有不少待优化，且鲁棒性泛化性水平仍存在不足。

(2) 解决方案:

我们计划引入更多型号（如 RA02、RA08 等）和更大量级（预估 60 台以上）的终端设备，以覆盖更大范围、更复杂环境下的数据采集任务。为更好的进行数据处理和模型结构问题查找和优化工作，以及为更之后的模型泛化性的提升打好基础。

我们预计的实验设备如下表所示:

表 1 实验规模方案表

设别型号	芯片	数量
RA01-SC	LLCC68	18
Dragino SX127x Shield	SX127x	10
Heltec LoRa32	SX1262	15
Heltec Cube Cell	SX1262	15
Ebyte EoRa S3	SX1268	10

2.3 泛化性水平提升方案

- (1) 问题描述：
- 当前的实验环境和实验设备具有一定的局限性，模型在面对新情况时泛化能力不足。当引入新的设备或环境变化时，往往需要对整个模型重新训练，不仅效率低下，也不适合在大规模设备数量和复杂多变的实际场景中部署与应用。
- (2) 解决方案：
- 为提升 LoRa 射频指纹识别模型在不同时间、设备、环境下的适应能力与鲁棒性，以及对于新设备，新环境下的泛化能力，我们提出以下方案：
- 1) 增强抗遗忘能力
- 引入弹性权重保护（EWC）机制，避免新设备学习时覆盖原有知识。建立关键样本缓存库（Replay），每类设备保留代表性 CFO 与相位差分特征用于混合训练。
- 2) 快速适应新设备/时间
- 采用局部微调机制，新样本仅更新分类器或 Adapter 模块，主干参数保持稳定。同时在推理阶段引入主模型+微调模型融合预测，提升新类识别的同时维持旧类准确性。
- 3) 存储与计算优化
- 使用 Attention-PCA 对设备指纹进行压缩，仅保存关键特征主成分，减少内存与计算开销。结合样本选择策略，提升数据代表性与模型泛化能力。

三、指导教师意见：

签字：日期

四、院系中期检查小组结论及意见：

☐ 优秀 ☐ 良好 ☐ 通过 ☐ 不通过

推荐排序：

签字：

日期

注：表头及第一、第二栏由学生负责人填写。（可附页）

中期报告检查报告

项目名称：基于连续双帧射频指纹的 LoRa 设备识别技术研究

指导老师：吴文甲

项目负责人：曹睿 学号：58122306

项目成员：刘博文 咎召朋 赵子辰

目录

1.项目背景	3
2.文献综述	4
2.1 射频指纹研究现状	4
2.2 物理层信号预处理技术	7
2.3 深度学习技术	11
2.4 特征工程技术	12
2.5 小结	13
参考文献	16
3.前期项目研究总结	19
3.1 技术调研	20
3.2 LoRa 信号数据的采集和预处理	21
3.3 基于相位差分特征的指纹识别模型	27
3.4 实验验证	32
4.项目后期研究方案	35
4.1 模型完善优化方案	35
4.2 实验规模扩大方案	37
4.3 泛化性水平提升方案	38
5.经费使用记录	38

1.项目背景

随着物联网（IoT）的蓬勃发展，其应用渗透到日常生活和工业生产的各个方面，例如智能家居、智慧医疗和工业 4.0 等。Statista 预测，到 2025 年全球物联网设备数量将达到 754.4 亿台[1]。低功耗广域网（LPWAN）作为一种新兴的物联网模式，能够有效支持大量轻量级设备的连接需求，其中，LoRa（Long Range）技术因其开源特性而被广泛研究和应用[2]。

LoRa 技术的快速发展和广泛应用导致设备数量急剧增加，其在物联网领域的重要性日益凸显。然而，针对 LoRa 网络的攻击也随之而来，例如隐蔽通道和信标欺骗攻击，严重威胁着 LoRa 物联网系统的安全性和稳定性。传统的基于强标识符和加密技术的身份验证方案由于容易被篡改或伪造，且对计算资源要求较高，难以适用于低成本和能源受限的 LoRa 设备。因此，研究一种高效、可靠的 LoRa 设备身份验证方法至关重要。

射频指纹（RFF）技术因其难以被篡改或伪造的特性，成为一种有潜力的轻量级身份验证解决方案。RFF 利用无线发射机在发送信号时产生的独特物理损伤特征来区分不同的设备。在连续双帧发送模式下，信号经历瞬态、半稳态和稳态阶段，可以提取更丰富的指纹特征。因此，本项目旨在设计一种基于连续双帧射频指纹的 LoRa 设备识别方案，通过提取稳定且具有高度鉴别力的连续双帧射频指纹特征，实现对 LoRa 设备的精确和稳定身份验证，从而增强 LoRa 物联网系统的安全性。

目前，射频指纹识别方案主要分为人工提取特征和深度学习（DL）两种。合法设备识别通常被视为一个多分类任务。在基于人工提取特征的方案中，载波频率偏移展现出显著的效果，准确率普遍达到 95%以上[3]。然而，该方法易受温度变化的影响，导致性能漂移。一些研究者通过建立载波频率偏移数据库来缓解温度漂移问题[4]，但这需要获取设备晶振温度，限制了其应用范围。IQ 不平衡、相位噪声等特征相对稳定[5]，但其区分度有限，通常需要组合成混合分类器。基于深度学习的方案主要采用卷积神经网络（CNN）或递归神经网络（RNN）。凭借深度学习强大的特征提取能力，对于大规模设备识别也能达到 95%以上的准确率。然而，深度学习方法容易出现过拟合问题，导致泛化能力较差[6]。在真实环境中，无线信号从发射机到接收机的传输会受到无线信道的影响，且这种影响是时变的。用于深度学习的数据通常包含信道影响，神经网络可能会学习到特定时间段的信道特性，从而影响分类器的泛化能力。当训练集和测试集在不同时间采集时，深度学习方案的准确率会显著下降[6]。此外，训练神经网络需要大量数据且耗时，如果分类器需要频繁更新，这对认证机制

来说是不可接受的。一种更合适的方法是先对原始信号进行专家知识处理，然后再将处理后的数据输入深度学习算法。数据扩增作为一种数据预处理技术，可以有效提升神经网络分类器的泛化能力。

基于以上背景，如何在真实信道环境的影响下，提取具有时变稳定性的射频指纹特征，并设计具备非法设备检测和设备识别功能的认证机制，是 LoRa 物联网系统面临的重要问题。通过分析射频信号的状态，本项目发现连续发出的两个帧具有更稳定、更有区分度的射频指纹。因此，本项目研究基于连续双帧射频指纹的 LoRa 设备认证机制，通过 LoRa 设备连续发送两个帧（即连续双帧），挖掘更深层次的指纹，以提升认证机制的时变稳定性。在连续双帧的前提下，本项目将研究信道无关处理算法，以减缓信道效应；利用深度学习技术，设计并实现一种设备检测算法；研究载波频率偏移和相位噪声的变化情况，利用机器学习技术，设计一种混合特征分类器，以实现设备识别算法。

在理论研究成果的基础上，本项目将设计并实现一套基于连续双帧射频指纹的 LoRa 终端认证原型系统，提出基于连续双帧的 LoRa 射频指纹识别方案，利用双帧信号的相位噪声差分特征，增强指纹的稳定性和区分度。优化数据采集与特征提取，确保双帧模式下的指纹特征在不同环境下仍具备较强的鲁棒性。构建 LoRa 射频指纹数据库，结合机器学习分类器，实现高效、可扩展的设备认证方案。实验验证方案的有效性，在不同信道条件（包括非视距 NLoS 场景）下评估识别准确率，并与现有深度学习方法进行对比分析。

2. 文献综述

项目组针对射频指纹研究，通过文献阅读分析了国内外研究团队的相关工作，并调研了其涉及到的物理层信号处理技术，深度学习技术和特征工程技术。

2.1 射频指纹研究现状

射频指纹（Radio Frequency Fingerprinting, RFF）技术利用无线设备硬件的固有特性进行身份认证，已成为物联网安全领域的重要研究方向。本节从基于深度学习的射频指纹识别和基于特征工程的射频指纹识别两个方面展开现状分析，并结合连续双帧的概念，探讨其在 LoRa 设备识别中的应用潜力。

（1）基于深度学习的射频指纹识别

随着深度学习在图像、语音等领域的成功应用，其在无线信号处理中的潜

力逐渐被挖掘。基于深度学习的射频指纹识别方案无需人为设计特征提取流程，能够自动挖掘信号中的高维特征，尤其是针对 LoRa 协议的帧信号表现出较强的适应性。近年来，研究重心逐步向深度学习倾斜，尤其是在 LoRa 设备识别中，深度学习方法展现出显著优势。

1) 早期研究的模型设计

早期研究聚焦于如何将 LoRa 信号与深度学习结合，以及选择何种信号表现形式以提升识别效果。Robyns 等人[7]受到图像领域监督学习和零样本学习（Zero-Shot Learning）的启发，提出了一种基于整个 LoRa 帧信号的神经网络分类器。该方法不依赖局部特征，针对相同芯片设备的识别准确率达到 59%~99%，不同芯片设备达到 99%~100%，而零样本学习对未训练标签的识别准确率为 65%，50 英尺距离内实现 90%~99% 的识别准确率，优于传统方法如逻辑回归（LR）和支持向量机（SVM）。Shen 等人[9]比较了原始 IQ 样本、快速傅里叶变换（FFT）结果和频谱图三种表现形式，发现频谱图在 CNN 中的识别效果最佳，且训练速度更快。Al-Shawabka 等人[10]进一步评估了 IQ 样本、幅度-相位和频谱图，发现幅度-相位和频谱图在中小规模 LoRa 设备识别中表现更优。此外，他们对比了帧前导和有效载荷，发现有效载荷部分的识别效果优于前导部分。这些研究为连续双帧方法提供了启发，即利用多帧信号可能进一步挖掘时序特征。

2) 基于硬件损伤的特征挖掘

硬件损伤是射频指纹的理论基础，研究者尝试通过深度学习建模不同损伤特征以提升识别精度。Shen 等人[9]研究了载波频率偏移（CFO）的时漂特性，发现其不可避免但大致稳定，可通过补偿后结合频谱图输入 CNN，构建混合分类器，在 20 个 LoRa 设备中实现 97.61% 的准确率。Zhang 等人[11]对窄带系统硬件损伤（包括 CFO、IQ 不平衡和功率放大器非线性）进行系统建模，发现 CFO 受温度影响不适合直接使用，而 IQ 不平衡和功率放大器非线性在深度学习模型中表现更好，50 个设备准确率为 99%，200 个设备为 89%。Hanna 等人[12]聚焦功率放大器非线性，通过通用软件无线电外设（USRP）的非线性曲线建模，验证了深度学习在复杂信道下的识别性能。这些研究表明，连续双帧方法可通过捕捉帧间硬件损伤的连续性变化，进一步提升特征稳定性。




图 1 具有硬件损伤的发射机链

3) 信道效应的鲁棒性研究

深度学习易受信道时变性影响，导致过拟合问题。Al-Shawabka 等人[4]发现，当训练集与测试集非同一天采集时，10 个 LoRa 设备的识别准确率仅为 19%，通过数据扩增提升至 36%。Restuccia 等人[13]提出在发射端使用优化 FIR 滤波器调整波形，在 500 个设备的数据集上提升 50%以上准确率。Shen 等人[10]针对低信噪比（SNR）场景，采用 Transformer 模型处理可变长度信号，并结合数据扩增和多包推理，将低 SNR 下的识别性能提升 70%以上。针对连续双帧方法，帧间信道变化可能放大时变效应，但通过多帧联合分析或数据扩增，有望缓解这一问题。

4) 非法设备检测的扩展性研究

设备动态加入或离开时，深度学习模型需重新训练，限制了扩展性。Shen 等人[8]设计了仅需训练一次的射频指纹提取器，并提出非法设备检测算法，结合信道无关频谱图和数据扩增，在 60 个 LoRa 设备中实现 88.67%的识别准确率和 0.9905 的 ROC-AUC 值。Li 等人[15]利用 OFDM 导频和频域变换提取设备无关指纹，在高 SNR 下实现 95%以上准确率。Huang 等人[16]基于傅里叶同步压缩变换（FSST）和监督对比学习，在低 SNR（5dB）下达到 82%准确率。连续双帧方法可通过帧间特征一致性检测非法设备，提升扩展性和安全性。

（2）基于特征工程的射频指纹识别

相比深度学习，基于特征工程的方法利用专家知识提取硬件损伤特征，具有可解释性强、计算需求低的优势。针对 LoRa 协议，研究者通过分析载波频率偏移、IQ 不平衡等特征，设计了多种识别方案。

1) 特征提取与表示

差分星座图是常见的特征表示方法。Peng 等人[17]提出通过相邻符号差分消除信道影响，保留 CFO 和 IQ 不平衡特征，在 15dB SNR 下实现 16 个 Zigbee 设备 90%以上的准确率。Wu 等人[18]将该方法应用于 LoRa，4 个设备准确率达 98.66%。Song 等人[19]结合 K 最近邻（KNN）算法，在 15dB SNR 下 4 个 LoRa 设备准确率为 99%，-12dB SNR 下仍达 86%。连续双帧方法可扩展差分思想，通过两帧间的特征差分增强指纹独特性。

2) 多特征联合分析

Brik 等人[14]设计 PARADIS 系统，综合测量调制域特征（如 CFO 和 IQ 不平衡），结合 KNN 和 SVM，识别 100 多个 802.11b 网卡，准确率超 99%。Kandel 等人[21]利用 MIMO-OFDM 发射机的相位偏移差值，在 17 个 Intel 网卡中实现 97%（静止）和 92%（移动）的准确率。Yan 等人[22]通过数据扩增和信噪比补偿，设计 RRF 系统，在复杂信道下识别 10 个设备，准确率达 99%。这些方法表明，多帧联合分析（如连续双帧）可通过特征组合提升性能。

3) 外界因素建模

外界因素如温度和信道对特征影响显著。Gu 等人[23]针对 CFO 受温度变化，提出 TeRFF 系统，通过温度感知和 CFO 估计，在 15 台智能手机中实现 70%准确率。Zheng 等人[24]将信号生成过程建模为 FID 函数，抵御重放攻击，在 33 个设备中准确率超 99%。连续双帧方法可通过帧间特征变化建模外界影响，进一步提高鲁棒性。

2.2 物理层信号预处理技术

为了提取射频指纹，通常需要对 LoRa 信号分别进行帧同步、前导码提取、载波频偏补偿和归一化。

（1）帧同步

信号采集后往往是一串无间断的信号流，为了将 LoRa 设备发出的每个数据包分离出来作为后续的训练和测试样本，需要对定位每个 LoRa 帧的起点，这样的定位检测过程称为“同步”，本项目的数据预处理中“同步”操作主要分为两个步骤，分别是“粗同步”和“精同步”：

粗同步：定位 LoRa 的关键是找到帧起点，LoRa 帧的第一部分是前导码，而前导码的起始部分是由多个相同的 upchirp 组成的。为了利用 LoRa 帧中前

导码的重复性质，采用经典的帧同步算法 Schmidl-Cox 算法进行 LoRa 的粗同步操作。

Schmidl-Cox 算法是一种用于在正交频分复用（OFDM）系统中同步信号的时序检测算法。OFDM 系统通常在无线通信和高速数据传输中广泛应用，Schmidl-Cox 算法的主要目标是准确确定 OFDM 信号的起始点或帧同步位置。这一起始点的确定对于成功解调和解码接收到的 OFDM 信号至关重要。为了确保接收端能够准确地恢复发送端的数据，需要在接收端进行帧同步，即找到发送端开始发送数据的时刻。Schmidl-Cox 算法通过利用已知的训练序列，即导频符号，来实现帧同步

Schmidl-Cox 算法同样适用于本文中含有重复结构前导码的 LoRa 信号，Schmidl[25]在 1997 年提出该算法的两个重要的计算指标和定义如下：

$$P(n) = \sum_{k=0}^{L-1} r[n+k] \cdot r^*[n+k+L] \quad (1)$$

$$R(n) = \sum_{k=0}^{L-1} r[n+k+L] \cdot r^*[n+k+L] \quad (2)$$

$$M(n) = \frac{|P(n)|}{R(n)} \quad (3)$$

其中， L 表示 LoRa 帧前导码部分中一个 upchirp 的长度， n 表示 $r[n]$ 信号的第 n 个采样点， r^* 表示 $r[n]$ 信号的共轭信号， $P(n)$ 表示接收端的信号 $r[n]$ 在第 n 个采样点处与 $r[n+L]$ 的自相关系数，所谓的信号的自相关是通过将信号与其自身在时域中的滞后版本进行互相关计算得到的，所以 $P(n)$ 是信号 $r[n]$ 与自身信号滞后 L 个采样点的信号 $r[n+L]$ 进行的互相关计算，而恰好由于 LoRa 信号的前导码部分有十分明显的 upchirp 重复元素，因此随着 n 点的不断变化， $P(n)$ 会产生一个极值，即当前信号的 upchirp 与滞后版本的信号的 upchirp 重合，以此可以说明 n 此时的是信号 $r[n]$ 中 LoRa 帧的起点，第二个式子是对 $P(n)$ 的归一化操作。最终的 $M(n)$ 的极值即是判断当前第 n 个采样点是否是 LoRa 帧起点的标志。

精同步：虽然 Schmidl-Cox 算法可以有效地确定 LoRa 帧中前导码的存在，但本质是一个时序指标，极值附近会存在平台区域导致了对前导码开始的不确定性。为了解决该问题，本项目只使用带有阈值的标准 Schmidl-Cox 度量来替代取的极值的方式对信号进行粗同步，此时的信号在真正的前导码前面仍会存在少量的噪声点，则需要进行接下来的精同步。

这里参考 Robyns[26]等人根据 LoRa 信号的独特特性，提出的一种有效的

精同步算法。他们提出了一种多信道软件解码器，用于 LoRa 调制方案。该方法通过软件定义无线电（SDR）实现对多个 LoRa 信道的并行解码，而不依赖于专用硬件网关。涉及到信号中瞬时频率的计算，瞬时频率是指信号在某一时刻的瞬时频率值，它表示信号在该时刻的频率特性或周期性变化情况。对于离散时间信号，瞬时频率可以通过信号相位的差分来估计。假设离散时间信号的相位为 $\theta[n]$ ，则其瞬时频率 $f[n]$ 可以近似计算为：

$$f[n] = \frac{(\theta[n] - \theta[n-1])}{T} \quad (4)$$

精同步算法首先会在接收机处产生一个理想的基带 upchirp 信号，然后需要计算其瞬时频率，由于 upchirp 是一个特殊的信号单元，其瞬时频率即为随时间线性增的频率，具体表示如下式所示：

$$f_{ideal}[n] = -\frac{B}{2} + \frac{B}{T} * NT_s \quad (5)$$

其中 T 表示 upchirp 的周期，表示离散信号的采样间隔。然后，接收机需要计算出粗同步之后的基带信号的瞬时频率，最后计算与之间的互相关函数，具体计算公式如下式：

$$\text{start} = \arg \max_{i \in \{0,1,\dots,L-1\}} \left(\sum_{n=0}^{L-1} f_{ideal}[n] \cdot \hat{f}_r[n - i] \right) \quad (6)$$

此时上式计算的范围是在一个长度为 L 的窗宽之间，由于前序操作已经确定了 LoRa 帧的存在，只需要计算在前 L 个信号采样点的互相关系数即可确定准确的 LoRa 的起点。

（2）前导码提取

在本项目是基于特征工程的方法，所以 LoRa 帧的原始特征对于后续的分类起到关键作用。如图所示，前导码是 LoRa 帧的第一部分，由 m 个上啁啾符号组成，其中，默认值为 8。前导部分的作用就是进行同步。由于前导出现在每一帧中，其内容具有确定性，因此常用于射频指纹识别。同步完成后，通过获取开头的前 m 个符号提取前导。




图 2 LoRa 帧结构图

(3) 载波频偏补偿

CFO 即载波频率偏移, 通常指的是实际接收到的信号的载波频率与理论预期的载波频率之间的差异。造成载波频率偏移的原因有多种, 包括发射端和接收端设备的本地振荡器频率不准确、环境温度变化、电源变化以及信号传输过程中的多径效应等都会在一定程度上造成 CFO, 从而影响系统的可靠性。在 Shen[27]等人的研究中,他们重点讨论了长期和短期内温度变化对于 LoRa 信号 CFO 的影响, 同时也指出, CFO 会对 LoRa 射频指纹识别的准确率造成较大影响所以需要对信号的产生的 CFO 进行补偿操作, 与“同步”操作类似, 分为“粗 CFO 补偿”和“精 CFO 补偿”。由于 LoRa 帧的前导码的重复性质, 接收端的信号可以变化为:

$$f_p[n] = -\frac{B}{2} + \Delta f + \frac{B}{T_s} + \frac{B}{T_s} nT_s \quad (7)$$

其中 Δf 则表示接收端信号的 CFO。

粗 CFO 补偿: 因为是随时间线性变化的频率曲线, 粗 CFO 可以利用接收端前导码的瞬时频率随时间的均值进行估计, 此时的粗 CFO 可以由下式表示:

$$\Delta f_{\text{coarse}} = \frac{1}{L} \sum_{n=0}^{L-1} f_p[n] \quad (8)$$

所以对原始接收端的前导码信号进行粗 CFO 补偿得到, 如下式所示:

$$r'_p[n] = r_p[n] \cdot e^{-j2\pi\Delta f_{\text{coarse}}nT_s} \quad (9)$$

精 CFO 补偿: 粗的 CFO 补偿并不足够准确, 补偿后仍有一些残余的 CFO。因此, 需要采取一种精细的 CFO 估计方式进行进一步的 CFO 补偿, 补偿公式如下式:

$$\widehat{\Delta f_{\text{coarse}}} = -\frac{1}{2\pi T_s} \angle \left(\sum_{n=0}^{L-1} r'_p[n] \cdot r'^{*}_p[n+L] \right) \quad (10)$$

其中计算的复数的角度, 式中主要体现的仍是一个自相关的思想, 通过计算前导码中重复结构在接收端的相似程度判断存在的残余 CFO, 进一步 $r[n]$ 经过精 CFO 补偿得到 $r''[n]$, 如下式所示:

$$r''_p[n] = r'_p[n] \cdot e^{-j2\pi\widehat{\Delta f_{\text{coarse}}}nT_s} \quad (11)$$

(4) 归一化

信号强度的差异被视为硬件损伤特征之一，但是其受发射机功率和通信距离的影响很大，通常不能直接被用来设备识别，可使用相应的归一化方法消除其影响。幅度归一化是射频指纹识别系统中的一个必须的过程，通过接收端信号的振幅的均方根进行归一化，经过幅度归一化的信号如式所示：

$$s[n] = \frac{r''_p[n]}{\|r''_p[n]\|} \quad (12)$$

其中是 CFO 补偿后的信号的幅度的均方根。

2.3 深度学习技术

(1) 深度学习在信号处理中的应用

随着深度学习技术的发展，其在传统信号处理领域中的应用逐渐深入，尤其是在自动特征提取和端到端建模方面展现出显著优势。相比于传统的信号处理方法，如傅里叶变换、小波分析等，深度神经网络（DNN）能够自动从原始信号中学习多层次的特征表示，提升分类与识别精度。卷积神经网络（CNN）被广泛应用于一维信号分类任务，如心电图（ECG）、地震波形识别和无线信号调制分类，其优势在于局部感知和权值共享机制，有效降低模型复杂度此外，递归神经网络（RNN）及其变种（如 LSTM 和 GRU）在建模时间序列信号方面表现出良好的效果，能够捕捉长时间依赖关系，适用于语音识别、脑电信号（EEG）分析等任务。

(2) 分类任务中的深度学习模型

在信号分类任务中，基于深度学习的方法多采用监督学习框架。近年来，多模态深度学习方法也被提出以进一步提升性能，通过融合来自多个传感器或特征源的信息来增强分类的鲁棒性。研究表明，融合卷积网络和注意力机制（Attention Mechanism）可以进一步提高信号分类的准确率与泛化能力[28]。

同时，Transformer 架构逐渐被引入一维信号建模任务中，其强大的全局建模能力使其在复杂信号的识别与分类中具有竞争优势[29]。

(3) 持续学习（Continual Learning）在信号分类中的挑战与进展

在实际应用中，信号数据往往具有非静态性，新的类别或模式可能不断出

现，这对模型的适应能力提出更高要求。传统的深度学习模型在面对新任务时容易发生灾难性遗忘（catastrophic forgetting），即在学习新任务时遗忘旧任务的知识。

为了解决这一问题，研究者提出了多种持续学习策略，主要包括正则化方法（如 Elastic Weight Consolidation, EWC）[30]，通过限制关键参数的更新程度，保留旧知识。动态网络结构，例如 Progressive Neural Networks[31]，通过引入新模块来处理新任务，避免对旧网络参数的修改。回放机制（Rehearsal/Replay）[32]，通过保存一部分旧数据或利用生成模型合成旧任务样本，来辅助新任务训练。

尽管如此，在信号处理任务中实现高效的持续学习仍存在挑战，尤其是在数据隐私限制、样本不平衡和计算资源受限的实际场景下。

2.4 特征工程技术

特征工程（Feature Engineering）是机器学习和数据科学中至关重要的一步，它涉及从原始数据中提取、转换和选择特征，以便更好地表示数据的潜在模式，从而提高模型的性能。特征工程的目标是创建对模型预测任务最有帮助的特征，同时减少噪声和冗余。常用的方法包括特征提取、转换、选择、编码、交互等

特征工程在不同领域有着广泛应用，例如 Chen 等人[33]利用 SIFT、HOG、PCA 降维，从图像数据中提取边缘、纹理和颜色直方图等特征，用于图像分类，Zhang 等人[34]节点度、PageRank、特征交互,从社交网络数据中提取影响最大化相关特征.

在本项目中，基于特征工程的射频指纹识别，与深度学习相比，具有可控性和可解释性强等优点。CFO 表现出了很出色的识别性能，因此很多工作都围绕它展开。如，在特征提取与表示上，Peng 等人[35]通过相邻符号差分消除信道线性偏移，在 16 个 Zigbee 设备上实现 90%以上的识别准确（SNR=15dB）。在外界因素建模上，Gu 等人[36]开发的 TeRFF 系统通过温度-CFO 映射模型，在动态温度场景下识别准确率达 70%，较传统 CFO 方案提升 40%。在多特征联合分析上，Brik 等人[37]设计 PARADIS 系统，综合测量调制域特征（如 CFO 和 IQ 不平衡），结合 KNN 和 SVM，识别 100 多个 802.11b 网卡，准确率超 99%。

特征工程是一个迭代和创造性的过程，需要结合数据的特点和任务的目标。好的特征工程可以显著提升模型的性能，但需要大量的实验和领域知识支持。

在实际应用中，特征工程往往是机器学习项目中耗时最多、最关键的环节之一。

2.5 小结

(1) 目前研究的局限性

1) 基于深度学习的方案

当前神经网络在 LoRa 设备指纹识别中的应用虽然取得了较高的准确率，但仍面临诸多挑战，限制了其在实际场景中的广泛部署。首先，模型的泛化能力不足。许多研究表明，该类模型对信道条件的时变性高度敏感，一旦训练与测试数据采集的时间间隔拉长，识别性能将大幅下降。Al-Shawabka 等人

(2021) 的研究显示，在 10 台 LoRa 设备的实验中，若训练集和测试集的采集时间间隔超过 24 小时，模型识别准确率会从 98%骤降至 36%，揭示了严重的时间泛化失效问题[38]。这说明模型可能在学习过程中将信道特征误判为设备指纹，从而导致过拟合风险显著增加。

其次，当前方法在系统可扩展性方面也存在明显瓶颈。由于神经网络通常是“闭集”学习，设备集合一旦发生变化，例如新设备的加入或已有设备的离网，就需要重新训练整个模型，这对于实际部署场景尤其是在大规模动态环境中来说，代价极其高昂。此外，训练和推理过程往往依赖于 GPU 等高性能计算资源，尤其是在引入 Transformer 结构后对算力的需求进一步提高。这使得模型难以迁移到资源受限的边缘设备或低功耗场景中运行，严重限制了其实用性[39]。

综上所述，LoRa 设备指纹识别的神经网络方法亟需在提高时空泛化能力、降低过拟合风险、增强系统弹性和适应边缘部署等方面进行改进和优化，以实现更加稳定和可持续的实际应用。

2) 基于特征工程的方案

尽管当前的无线设备指纹识别技术在理想条件下表现出较高的识别准确率，但在实际复杂环境中仍面临诸多技术挑战。首先，方法的协议依赖性较强。以差分星座图 (Differential Constellation Trace, DCT) 为代表的一类方法，需要针对特定通信协议进行定制化设计。例如在 LoRa 系统中，必须精确地进行符号边界对齐以获得有判别力的星座轨迹[40]。然而，该对齐算法通常 tightly coupled 于 LoRa 的跳频调制和符号结构，难以直接泛化或迁移到其他调制方

式如 OFDM（正交频分复用）等通信协议中。这种强依赖限制了设备指纹识别技术在跨协议、跨系统场景下的通用性和可复用性。

其次，关键物理层特征的稳定性存在矛盾。载波频率偏移（Carrier Frequency Offset, CFO）是当前广泛采用的区分性强的指纹特征之一，但其值容易受到设备温度、老化和硬件漂移等外部环境的影响，导致长期稳定性较差[41]。虽然相位噪声（Phase Noise）具有相对更高的稳定性，但其提取过程往往需要复杂的预处理步骤，如相位展开、去趋势与滤波等，显著增加了系统实现的复杂度。这种在“判别力”与“稳定性”之间的矛盾，成为影响指纹识别性能的关键因素。

此外，在低信噪比（SNR）条件下的鲁棒性仍是技术瓶颈。大量研究表明，当 SNR 低于 10 dB 时，无论是基于神经网络的方法，还是传统的特征提取方法，其识别准确率普遍下降至 80% 以下[42]。这使得系统在实际部署过程中，例如在复杂城市环境、远距离通信或强干扰场景下，易出现性能骤降甚至误识别，影响系统的可靠性与安全性。

因此，如何设计协议无关、环境鲁棒且在低 SNR 下依旧表现优异的指纹识别方法，是当前研究亟待解决的问题。

3) 共性挑战

在射频指纹识别系统中，非法设备检测能力的缺失仍是一项关键挑战。当前多数研究聚焦于封闭集分类，即假设所有待识别设备在训练阶段均已见过，这种设定难以应对实际中新设备动态加入或恶意设备接入的开放环境。在这种情况下，模型往往无法判断未知设备属于“非法”类，导致较高的误接受率（False Acceptance Rate, FAR），通常在 15% 至 20% 之间[43][44]。为应对这一问题，Shen 等人[45]提出了一种基于异常检测机制的 RF 指纹识别方案，设计了可泛化至未见设备的频谱图提取器，并通过监督对比学习构建判别边界，显著降低非法设备的接受率至约 10%。然而，该方法仍需依赖大量的数据扩增与手动设定阈值，鲁棒性和自动性尚不足。

此外，在低信噪比（SNR）环境下的识别性能下降也是深度学习方法面临的重要难题。传统基于相位噪声（Phase Noise）的指纹方案在 SNR 低于 10dB 时，准确率往往降至 80% 以下，主要由于相位信息极易被噪声污染[46]。而深度学习方法尽管在高 SNR 条件下具有显著优势，但其在低 SNR 场景下的泛化能力严重依赖于复杂的数据增强技术（如混合样本、加噪重构、对比损失等）[47][48]。例如，Huang 等人[49]引入傅里叶同步压缩变换（FSST）结合对比学

习策略，在 5dB 下实现 82%准确率，但仍需依赖大量训练数据与精细调参。Shen 等人[50]则采用多包融合推理与 Transformer 结构提升抗噪能力，在低 SNR 下显著改善性能，但训练成本与计算复杂度也相应提高。

因此，未来的非法设备检测系统需兼顾开放集识别能力与低信噪比鲁棒性，亟待开发更加轻量级、泛化性强的深度学习模型，或结合统计学习方法构建更具解释性的指纹判别机制。

（2）未来的发展方向

1) 混合模型设计：融合自动特征提取与特征工程的可解释性

在射频信号分类任务中，深度学习虽具备强大的自动特征提取能力，但其“黑盒”特性在某些应用场景下存在可解释性不足的问题。因此，近年来研究者提出将传统特征工程与深度模型融合，形成混合模型架构，以兼顾特征表达力与可解释性。例如，卷积神经网络（CNN）可以有效提取信号中的时频域高维特征，如能量分布、调制特性等[51]，而传统物理层特征（如差分相位噪声、包络偏差、瞬时频率）则能提供与设备硬件特性密切相关的可解释信息[52]。本研究拟设计一种轻量化的混合分类模型，前端采用 CNN 提取数据驱动特征，中间融合统计型和物理层手工特征，后端引入可裁剪的判别模块以适应不同计算平台。该模型将重点在于在不牺牲识别精度的前提下，实现更低的计算复杂度与更高的泛化能力，适用于实际部署场景如移动或边缘设备[53]。

2) 低功耗与高鲁棒性优化：面向物联网的边缘部署

在物联网（IoT）终端设备上部署射频指纹识别（RFF）系统时，必须面对计算资源受限、电池供电及传输带宽狭窄等现实约束。因此，研究的另一个核心方向是构建面向边缘计算的轻量化 RFF 框架。为此，本文将探索轻量级神经网络结构（如 MobileNet、TinyML）[54]，同时引入模型剪枝与量化技术以压缩模型参数，提高在边缘设备上的推理效率。此外，为增强模型在实际复杂无线环境中的适应性，拟开发噪声自适应算法，在低信噪比（ $\text{SNR} < 5 \text{ dB}$ ）条件下通过动态调节特征加权机制，提升系统对强干扰、噪声污染环境下的鲁棒性。这类自适应机制对于提升城市环境、远距离监测等场景中的识别稳定性具有重要意义[55]。

3) 安全与开放集识别：构建双重安全防线

射频指纹识别系统在实际部署过程中面临伪造攻击与非法设备接入等安全挑战。因此，安全性设计将成为系统架构中的关键组成部分。本文提出结合射

频指纹识别与物理层加密技术，构建“双重安全防线”架构。一方面，利用物理层不可克隆特性实现设备级身份验证；另一方面，引入轻量级加密机制（如物理不可克隆函数，PUF）保障通信链路的安全性[56]。此外，传统分类模型往往难以应对“开放集”场景，即模型在部署后可能接收到未见过的新类设备信号。对此，本文将探索开放集识别方法，如基于最大熵或可信度边界的判别策略，确保系统在面对未知设备时能拒绝输出或进行后续审核[57]，从而显著提升整体系统的安全鲁棒性。

参考文献

- [1] IoT devices installed base worldwide 2015-2025[EB/OL]. [2023-02-10]. <https://www.statista.com/statistics/471264/iot-number-of-connected-devices-worldwide/>.
- [2] Li C, Cao Z. LoRa Networking Techniques for Large-scale and Long-term IoT: A Down-to-top Survey[J]. ACM Computing Surveys, 2023, 55(3): 1-36.
- [3] Shen G, Zhang J, Marshall A, et al. Radio Frequency Fingerprint Identification for LoRa Using Spectrogram and CNN[C]//IEEE INFOCOM 2021 - IEEE Conference on Computer Communications. 2021: 1-10.
- [4] Gu X, Wu W, Guo N, et al. TeRFF: Temperature-aware Radio Frequency Fingerprinting for Smartphones[C]//2022 19th Annual IEEE International Conference on Sensing, Communication, and Networking (SECON). 2022: 127-135.
- [5] Zhang J, Woods R, Sandell M, et al. Radio Frequency Fingerprint Identification for Narrowband Systems, Modelling and Classification[J]. IEEE Transactions on Information Forensics and Security, 2021, 16: 3974-3987.
- [6] Al-Shawabka A, Pietraski P, Pattar S B, et al. DeepLoRa: Fingerprinting LoRa Devices at Scale Through Deep Learning and Data Augmentation[C]//Proceedings of the Twenty-second International Symposium on Theory, Algorithmic Foundations, and Protocol Design for Mobile Networks and Mobile Computing. New York, NY, USA: Association for Computing Machinery, 2021: 251-260.
- [7] Robyns P, Marin E, Lamotte W, et al. Physical-layer fingerprinting of LoRa devices using supervised and zero-shot learning[C]//Proceedings of the 10th ACM Conference on Security and Privacy in Wireless and Mobile Networks. New York, NY, USA: Association for Computing Machinery, 2017: 58-63.
- [8] Riyaz S, Sankhe K, Ioannidis S, et al. Deep Learning Convolutional Neural Networks for Radio Identification[J]. IEEE Communications Magazine, 2018, 56(9): 146-152.
- [9] Shen G, Zhang J, Marshall A, et al. Radio Frequency Fingerprint Identification for LoRa Using Spectrogram and CNN[C]//IEEE INFOCOM 2021 - IEEE Conference on Computer Communications. 2021: 1-10.
- [10] Al-Shawabka A, Pietraski P, Pattar S B, et al. DeepLoRa: Fingerprinting LoRa Devices at Scale Through Deep Learning and Data Augmentation[C]//Proceedings of the Twenty-second International Symposium on Theory, Algorithmic Foundations, and Protocol Design for Mobile Networks and Mobile Computing. New York, NY, USA: Association for Computing Machinery, 2021: 251-260.

- [11] Zhang J, Woods R, Sandell M, et al. Radio Frequency Fingerprint Identification for Narrowband Systems, Modelling and Classification[J]. IEEE Transactions on Information Forensics and Security, 2021, 16: 3974-3987.
- [12] Hanna S S, Cabric D. Deep Learning Based Transmitter Identification using Power Amplifier Nonlinearity[C]//2019 International Conference on Computing, Networking and Communications (ICNC). 2019: 674-680.
- [13] Restuccia F, D'Oro S, Al-Shawabka A, et al. DeepRadioID: Real-Time Channel-Resilient Optimization of Deep Learning-based Radio Fingerprinting Algorithms[C]//Proceedings of the Twentieth ACM International Symposium on Mobile Ad Hoc Networking and Computing. New York, NY, USA: Association for Computing Machinery, 2019: 51-60.
- [14] Shen G, Zhang J, Marshall A, et al. Towards Scalable and Channel-Robust Radio Frequency Fingerprint Identification for LoRa[J]. IEEE Transactions on Information Forensics and Security, 2022, 17: 774-787.
- [15] Li G, Yu J, Xing Y, et al. Location-Invariant Physical Layer Identification Approach for WiFi Devices[J]. IEEE Access, 2019, 7: 106974-106986.
- [16] Gong J, Xu X, Lei Y. Unsupervised Specific Emitter Identification Method Using Radio-Frequency Fingerprint Embedded InfoGAN[J]. IEEE Transactions on Information Forensics and Security, 2020, 15: 2898-2913.
- [17] Peng L, Hu A, Jiang Y, et al. A differential constellation trace figure based device identification method for ZigBee nodes[C]//2016 8th International Conference on Wireless Communications & Signal Processing (WCSP). 2016: 1-6.
- [18] Wu X, Jiang Y, Hu A. LoRa Devices Identification Based on Differential Constellation Trace Figure[C]//Sun X, Wang J, Bertino E. Artificial Intelligence and Security. Cham: Springer International Publishing, 2020: 658-669.
- [19] 宋宇波, 耿益瑾, 李古月, 等. 基于差分星座轨迹图的 LoRa 设备识别方法[J]. 信息安全, 2021, 21(01): 41-48.
- [20] Brik V, Banerjee S, Gruteser M, et al. Wireless device identification with radiometric signatures[C]//Proceedings of the 14th ACM international conference on Mobile computing and networking. New York, NY, USA: Association for Computing Machinery, 2008: 116-127.
- [21] Kandel L N, Zhang Z, Yu S. Exploiting CSI-MIMO for Accurate and Efficient Device Identification[C]//2019 IEEE Global Communications Conference (GLOBECOM). 2019: 1-6.
- [22] Yan W, Voigt T, Rohner C. RRF: A Robust Radiometric Fingerprint System that Embraces Wireless Channel Diversity[C]//Proceedings of the 15th ACM Conference on Security and Privacy in Wireless and Mobile Networks. New York, NY, USA: Association for Computing Machinery, 2022: 85-97.
- [23] Gu X, Wu W, Guo N, et al. TeRFF: Temperature-aware Radio Frequency Fingerprinting for Smartphones[C]//2022 19th Annual IEEE International Conference on Sensing, Communication, and Networking (SECON). 2022: 127-135.
- [24] Zheng T, Sun Z, Ren K. FID: Function Modeling-based Data-Independent and Channel-Robust Physical-Layer Identification[C]//IEEE INFOCOM 2019 - IEEE Conference on Computer Communications. 2019: 199-207.

- [25] Schmidl T M, Cox D C. Robust frequency and timing synchronization for OFDM[J]. IEEE transactions on communications, 1997, 45(12): 1613-1621.
- [26] Robyns P, Quax P, Lamotte W, et al. A Multi-Channel Software Decoder for the LoRa Modulation Scheme[C]//IoTBDS. 2018: 41-51.
- [27] Shen G, Zhang J, Marshall A, et al. Radio frequency fingerprint identification for LoRa using deep learning[J]. IEEE Journal on Selected Areas in Communications, 2021, 39(8): 2604-2616.
- [28] Zhou, Y., et al. (2021). "Multi-modal signal fusion for human activity recognition using deep learning." *Information Fusion*, 74, 99–110.
- [29] Vaswani, A., et al. (2017). "Attention is all you need." In **NeurIPS**, 5998–6008.
- [30] Kirkpatrick, J., et al. (2017). "Overcoming catastrophic forgetting in neural networks." *PNAS*, 114(13), 3521–3526.
- [31] Rusu, A. A., et al. (2016). "Progressive neural networks." *arXiv preprint arXiv:1606.04671**.
- [32] Shin, H., et al. (2017). "Continual learning with deep generative replay." *NeurIPS*, 2990–2999.
- [33] Chen Z, Wu Y. Feature Engineering for Image Classification Using Deep Learning[C]//2019 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 1-9
- [34] Liu Y, Zhang X. A Comprehensive Study on Feature Engineering for Influence Maximization in Social Networks[J]. *Social Network Analysis and Mining*, 2021, 11(1): 1-20.
- [35] Pan Y, Yang S, Peng H, et al. Specific Emitter Identification Based on Deep Residual Networks[J]. *IEEE Access*, 2019, 7: 54425-54434.
- [36] Gu X, Wu W, Guo N, et al. TeRFF: Temperature-aware Radio Frequency Fingerprinting for Smartphones[C]//2022 19th Annual IEEE International Conference on Sensing, Communication, and Networking (SECON). 2022: 127-135.
- [37] Brik V, Banerjee S, Gruteser M, et al. Wireless device identification with radiometric signatures[C]//Proceedings of the 14th ACM international conference on Mobile computing and networking. New York, NY, USA: Association for Computing Machinery, 2008: 116-127.
- [38] Al-Shawabka, A. et al. (2021). Exposing the Fingerprint of LoRa Devices via CNN-based Classification. *IEEE Symposium on Security and Privacy (S&P)*.
- [39] Vaswani, A. et al. (2017). Attention is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [40] Sankhe, K. et al. (2020). *No Radio Left Behind: Radio Fingerprinting Through Deep Learning of Physical-Layer Hardware Impairments*. In **MobiCom**.
- [41] Soltanieh, M. et al. (2022). *On the Stability of RF Fingerprinting Features in Dynamic Environments*. **IEEE Transactions on Mobile Computing (TMC)**.
- [42] Al-Shawabka, A. et al. (2021). *Exposing the Fingerprint of LoRa Devices via CNN-based Classification*. In **IEEE S&P**.
- [43] G. Danev, H. Luecken, S. Capkun, and K. El Defrawy, "Attacks on physical-layer identification," **Proceedings of the third ACM conference on Wireless network security**, 2010.

- [44] L. Xiao, Y. Li, G. Han, et al., "PHY-layer spoofing detection with reinforcement learning in wireless networks," *IEEE Transactions on Vehicular Technology*, 2017.
- [45] C. Shen, F. Restuccia, et al., "One-Shot RF Fingerprint Learning for Unauthorized Device Detection," *IEEE Transactions on Information Forensics and Security*, 2022.
- [46] M. Lichtman et al., "A primer on physical layer identification: Techniques, applications and challenges," *IEEE Communications Surveys & Tutorials*, 2018.
- [47] Y. Liu, Z. Zhang, and Z. Han, "Adversarial Data Augmentation for Deep RF Fingerprint Learning under Low SNR," *IEEE Transactions on Wireless Communications*, 2022.
- [48] S. Riyaz et al., "Deep Learning for RF Fingerprinting in LoRaWAN," *IEEE Internet of Things Journal*, 2021.
- [49] Y. Huang et al., "FSST and Supervised Contrastive Learning for Robust RF Fingerprinting," *IEEE Transactions on Communications*, 2022.
- [50] C. Shen et al., "Robust Deep Learning-Based RF Fingerprinting under Time-Varying Channel Conditions," *IEEE Transactions on Cognitive Communications and Networking*, 2023.
- [51] O'Shea, T. J., & Corgan, J. (2016). "Convolutional radio modulation recognition networks." *International Conference on Engineering Applications of Neural Networks*.
- [52] Reising, D. R., et al. (2010). "Exploiting RF-DNA for Device Classification in Cognitive Radio Networks." *IEEE International Symposium on Dynamic Spectrum Access Networks*.
- [53] Zhang, X., et al. (2021). "Efficient Neural Network Design for Embedded AI: A Review." *ACM Transactions on Embedded Computing Systems*, 20(5s), 1–27.
- [54] Howard, A. G., et al. (2017). "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications." *arXiv preprint arXiv:1704.04861*.
- [55] Ali, M., et al. (2022). "Robust and Low-Complexity RF Fingerprinting for IoT Authentication in Noisy Environments." *IEEE Internet of Things Journal*, 9(6), 4567–4579.
- [56] Maes, R. (2013). *Physically Unclonable Functions: Constructions, Properties and Applications*. Springer.
- [57] Scheirer, W. J., et al. (2013). "Toward Open Set Recognition." *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 35(7), 1757–1772.

3.前期项目研究总结

从2024年10月立项，现已实施了5个月，项目组已从射频指纹设备识别、LoRa物理层信号预处理等方面做了充分地调研，设计实现了LoRa信号数据的采集和预处理方案，并初步构建了指纹识别模型。同时，开展了相应的实验验证工作，验证方案和模型的有效性。

3.1 技术调研

调研的目的是掌握课题的核心任务及现有解决方案，从而发现问题、提出改进方向，并为新方法的设计提供理论支持。作为本科生，我们的研究基础相对薄弱，因此需要广泛阅读文献，系统学习已有研究成果，才能更好地开展科研工作。

本研究小组围绕基于连续双帧的射频指纹识别展开了二十余篇相关文献的调研，项目组针对射频指纹研究，通过文献阅读分析了国内外研究团队的相关工作，并调研了其涉及到的物理层信号处理技术，深度学习技术和特征工程技术。同时，我们对部分论文中的关键算法进行了复现与对比分析，深入理解其识别性能、鲁棒性及计算成本等关键指标，以更好地评估和改进 LoRa 设备的身份认证方案。

本研究小组的调研围绕 LoRa 设备射频指纹识别展开，我们整理了核心论文，并详细记录其方法、数据集、实验结果等关键信息，汇总整理成表格，以便直观分析和比较各研究方案。

W3035 文档内容模板							
开始 插入 页面 公式 数据 审阅 视图 工具 会议共享 效率 WPS AI 搜索							
Jue		Q		f		分	
A	B	C	D	E	F	G	
1	论文名称	链接	发表时间	摘要	提出了什么方法	解决了什么问题	备注
2	Diff-ADF: Differential Adjacent-dual-frame Radio Frequency Fingerprinting for LoRa Devices	https	2024	近年来，LoRa无线电频率指纹识别因其轻量级特性和难以伪造的特点而受到广泛关注。现有的指纹提取方法主要分为两类，即基于深度学习的方法。基于深度学习的方法鲁棒性较差，并且模型训练需要大量资源成本。尽管基于特征工程的方法可以克服这些缺点，但其充分提取独特的设备特征，相位噪声特征提取，通过特征（如载波频率偏移（CFO）和相位噪声）区分能力不足。因此，本文提出了一种可扩展且对信道具有鲁棒性的RFFI框架，该框架由深度学习驱动的射频指纹（RFF）提取器和信道无关特征实现。具体而言，我们利用深度学习方法来训练RFF提取器，该提取器具有出色的泛化能力，能够从先从未见过的设备中提取RFF。任何设备均可通过预训练的RFF提取器提取RFF。RFF提取器可以提取RFF，并用于设备认证。此外，我们还提出了一种基于深度学习的LoRa无线电频率指纹识别（RFFI）方法，用于设备认证。具体方法包括：CFO（载波频率偏移）漂移问题的分析和补偿研究，信号表示方式的选择对深度学习方法性能的影响。论文比较了IQ采样、FFT结果和频谱图三种信号表示方式，确定频谱图更适合LoRa设备的瞬时载波频率偏移（CFO）会随时间漂移，导致误分类，并显著影响系统的稳定性。为此，本文提出CFO补偿技术，以降低CFO漂移对RFFI识别性能的影响。此外，研究团队设计了一种混合分类器，该分类器结合LoRa输出和CFO估计进行决策。当CNN预测的设备类别与对应的CNN在低信噪比条件下时，系统可以识别出同步性能。	LoRa设备的射频指纹识别问题，传统方法在低信噪比（SNR）和信道干扰情况下的识别能力较差，该方法提高了识别精度。信道影响导致的特征混淆问题，采用相邻双帧差分提取特征，减少信道对射频指纹的干扰。		
3	Towards Scalable and Channel-Robust Radio Frequency Fingerprint Identification for LoRa	https	2022	射频指纹识别的鲁棒性是我们处理相邻帧的差分相位噪声和载波频率偏移（CFO）漂移问题的关键。通过在不同射频指纹识别（RFFI）是一种基于发射硬件缺陷的设备认证技术，通过深度学习训练一个RFF提取器，使其具备良好的泛化能力，无线信道对射频指纹提取器的影响，由于信道效应可能影响RFF提取，该方法采用信道无关特征和数据增强来提高鲁棒性。	信道无关特征提取，通过特征选择和数据增强，降低无线信道对射频指纹的影响，提高识别的鲁棒性。能够从先从未见过的设备中提取RFF。设备可以随时通过预训练的RFF提取器提取RFF，并用于设备认证。	解决CFO漂移影响RFFI系统的稳定性问题。分析了CFO漂移对LoRa设备分类准确性的影响，并通过CFO补偿来缓解此问题，提高系统的稳定性。信号表示方式的选择对深度学习方法性能的影响。论文比较了IQ采样、FFT结果和频谱图三种信号表示方式，确定频谱图更适合LoRa设备的瞬时载波频率偏移（CFO）会随时间漂移，导致误分类，并显著影响系统的稳定性。为此，本文提出CFO补偿技术，以降低CFO漂移对RFFI识别性能的影响。此外，研究团队设计了一种混合分类器，该分类器结合LoRa输出和CFO估计进行决策。当CNN预测的设备类别与对应的CNN在低信噪比条件下时，系统可以识别出同步性能。	
4	Radio Frequency Fingerprint Identification for LoRa Using Deep Learning	https		无线频率指纹识别（RFFI）是一种新兴的设备认证技术，它依赖于无线设备的固有硬件特性。本文针对LoRa系统设计了一种基于深度学习的RFFI识别（RFFI）方法，用于设备认证。具体方法包括：CFO（载波频率偏移）漂移问题的分析和补偿研究，信号表示方式的选择对深度学习方法性能的影响。论文比较了IQ采样、FFT结果和频谱图三种信号表示方式，确定频谱图更适合LoRa设备的瞬时载波频率偏移（CFO）会随时间漂移，导致误分类，并显著影响系统的稳定性。为此，本文提出CFO补偿技术，以降低CFO漂移对RFFI识别性能的影响。此外，研究团队设计了一种混合分类器，该分类器结合LoRa输出和CFO估计进行决策。当CNN预测的设备类别与对应的CNN在低信噪比条件下时，系统可以识别出同步性能。	提出了一种基于深度学习的LoRa无线电频率指纹识别（RFFI）方法，用于设备认证。具体方法包括：CFO（载波频率偏移）漂移问题的分析和补偿研究，信号表示方式的选择对深度学习方法性能的影响。论文比较了IQ采样、FFT结果和频谱图三种信号表示方式，确定频谱图更适合LoRa设备的瞬时载波频率偏移（CFO）会随时间漂移，导致误分类，并显著影响系统的稳定性。为此，本文提出CFO补偿技术，以降低CFO漂移对RFFI识别性能的影响。此外，研究团队设计了一种混合分类器，该分类器结合LoRa输出和CFO估计进行决策。当CNN预测的设备类别与对应的CNN在低信噪比条件下时，系统可以识别出同步性能。	解决LoRa设备的射频指纹识别问题，传统方法在低信噪比（SNR）和信道干扰情况下的识别能力较差，该方法提高了识别精度。信道影响导致的特征混淆问题，采用相邻双帧差分提取特征，减少信道对射频指纹的干扰。	
5	Radio Frequency Fingerprint Identification for LoRa Using Spectrogram and CNN	https	2021	无线频率指纹识别（RFFI）是一种新兴的设备认证技术，它依赖于无线设备的固有硬件特性。本文针对LoRa系统设计了一种基于频谱图（Spectrogram）和卷积神经网络（CNN）的RFFI方案。具体而言，我们首先，研究人员采用频谱图作为LoRa信号的时频表示，以便深度学习方法更好地提取特征。此外，我们发现瞬时载波频率偏移（CFO）存在学习模型对设备特征提取的捕捉能力。相比于传统的符号的起始位置，并能校正多个子信道间隔的载波频率偏移，所提出的算法的运行性能接近Cramer-Rao下界（CRLB）对频偏估计方差的限制，并且由于多个子信道的固有平均效应，使得该方法在极低的信噪比（SNR）条件下实现稳健的帧同步、符号同步和载波频率偏移估计。	提出了一种基于频谱图（Spectrogram）和卷积神经网络（CNN）的无线频率指纹识别（RFFI）方法。首先，研究人员采用频谱图作为LoRa信号的时频表示，以便深度学习方法更好地提取特征。此外，我们发现瞬时载波频率偏移（CFO）存在学习模型对设备特征提取的捕捉能力。相比于传统的符号的起始位置，并能校正多个子信道间隔的载波频率偏移，所提出的算法的运行性能接近Cramer-Rao下界（CRLB）对频偏估计方差的限制，并且由于多个子信道的固有平均效应，使得该方法在极低的信噪比（SNR）条件下实现稳健的帧同步、符号同步和载波频率偏移估计。	解决LoRa设备的射频指纹识别问题，传统方法在低信噪比（SNR）和信道干扰情况下的识别能力较差，该方法提高了识别精度。信道影响导致的特征混淆问题，采用相邻双帧差分提取特征，减少信道对射频指纹的干扰。	
6	Robust frequency and timing synchronization for OFDM	https	1997	提出了一种用于正交频分复用（OFDM）系统的快速同步方法，该方法适用于在频率选择性信道上进行连续传输或突发操作。只需接收一个包含两个子信道的训练序列即可检测到信号的存在。该方法能够确定帧的起始位置，并能校正多个子信道间隔的载波频率偏移，所提出的算法的运行性能接近Cramer-Rao下界（CRLB）对频偏估计方差的限制，并且由于多个子信道的固有平均效应，使得该方法在极低的信噪比（SNR）条件下实现稳健的帧同步、符号同步和载波频率偏移估计。	提出了一种基于训练序列的鲁棒同步方法，用于正交频分复用（OFDM）系统的频率和定时同步。该方法采用特殊结构的训练序列，能够在低信噪比（SNR）条件下实现稳健的帧同步、符号同步和载波频率偏移估计。	解决LoRa设备的射频指纹识别问题，传统方法在低信噪比（SNR）和信道干扰情况下的识别能力较差，该方法提高了识别精度。信道影响导致的特征混淆问题，采用相邻双帧差分提取特征，减少信道对射频指纹的干扰。	
7	AMulti-Channel Software Decoder for the LoRa Modulation Scheme	https	2018	LoRa是一种专为低功耗广域网（LPWAN）设计的新型调制方案。本文提供了首个详细且完整的LoRa物理层（PHY）描述，并提出了一种基于软件定义无线电（SDR）的新型LoRa帧检测与解码方法。我们提出的解码方法能够在软件中高效解码多个信道，因为它对信号频率具有不变性。因此，该方法无需预先知道发射机或接收机引入的频率偏移误差。在实验评估中，我们使用了**三种软件定义无线电（USRP B210、HackRF和	提出了一种多信道软件解码器，用于LoRa调制方案。我们提出的解码方法能够在软件中高效解码多个信道，因为它对信号频率具有不变性。因此，该方法无需预先知道发射机或接收机引入的频率偏移误差。在实验评估中，我们使用了**三种软件定义无线电（USRP B210、HackRF和	解决了LoRa网络的扩展性和信道并行处理问题，为大规模LoRa部署物联网（IoT）应用提供了一种灵活、可扩展的软件解码方案。	

图 3 文献调研表 1




图 5 GNU Radio 信号采集项目流程图




图 6 GNU Radio 报文解析项目流程




图 7 GNU Radio 信号采集与解析流程图

本项目采用 18 台相同型号的 LoRa 设备进行数据采集，如图 3-4 和 3-5 所示。LoRa 设备配置 $SF = 7$ ，带宽 $B = 15\text{kHz}$ ，载波频率 $f_c = 433\text{MHz}$ 。在训练阶段，本项目从每个设备上各收集了 500 帧数据（即 250 组连续双帧）。




图 8 本项目用到的 LoRa 设备




图 9 正在发射信号的 LoRa 设备

(2) 数据预处理

接收到的信号受到硬件损伤的影响，这是制造过程的结果。为了提取硬件损伤引起的指纹，需要对接收信号进行处理，包括同步、前导提取、CFO 估计、

CFO 补偿和幅度归一化。



图 10 数据预处理模块流程图

1) 帧同步

信号采集后往往是一串无间断的信号流，为了将 LoRa 设备发出的每个数据包分离出来作为后续的训练和测试样本，需要对定位每个 LoRa 帧的起点，这样的定位检测过程称为“同步”，本项目的数据预处理中“同步”操作主要分为两个步骤，分别是“粗同步”和“精同步”：




图 11 自相关检测啁啾起点图

粗同步：定位 LoRa 的关键是找到帧起点，LoRa 帧的第一部分是前导码，而前导码的起始部分是由多个相同的 upchirp 组成的。为了利用 LoRa 帧中前导码的重复性质，采用经典的帧同步算法 Schmidl-Cox 算法进行 LoRa 的粗同步操作。

精同步：虽然 Schmidl-Cox 算法可以有效地确定 LoRa 帧中前导码的存在，但本质是一个时序指标，极值附近会存在平台区域导致了对前导码开始的不确定性。为了解决该问题，本项目只使用带有阈值的标准 Schmidl-Cox 度量来替代取的极值的方式对信号进行粗同步，此时的信号在真正的前导码前面仍会存在少量的噪声点，则需要进行精同步。




图 12 同步处理结果

2) 前导码提取

在本项目是基于特征工程的方法，所以 LoRa 帧的原始特征对于后续的分类起到关键作用。如图所示，前导码是 LoRa 帧的第一部分，由 m 个上啁啾符号组成，其中，默认值为 8。前导部分的作用就是进行同步。由于前导出现在每一帧中，其内容具有确定性，因此常用于射频指纹识别。同步完成后，通过获取开头的前 m 个符号提取前导。



图 13 LoRa 帧结构图

3) CFO 补偿

CFO 即载波频率偏移，通常指的是实际接收到的信号的载波频率与理论预期的载波频率之间的差异。造成载波频率偏移的原因有多种，包括发射端和接收端设备的本地振荡器频率不准确、环境温度变化、电源变化以及信号传输过程中的多径效应等都会在一定程度上造成 CFO，从而影响系统的可靠性。在 Shen 等人的研究中，他们重点讨论了长期和短期内温度变化对于 LoRa 信号 CFO 的影响，同时也指出，CFO 会对 LoRa 射频指纹识别的准确率造成较大影响，所以需要对信号产生的 CFO 进行补偿操作，与“同步”操作类似，分为“粗 CFO 补偿”和“精 CFO 补偿”。由于 LoRa 帧的前导码的重复性质，接收端的信

号可以变化为:

$$f_p[n] = -\frac{B}{2} + \Delta f + \frac{B}{T_s} + \frac{B}{T_s} nT_s \quad (13)$$

其中 Δf 则表示接收端信号的 CFO。

粗 CFO 补偿: 因为 $f_p[n]$ 是随时间线性变化的频率曲线, 粗 CFO 可以利用接收端前导码的瞬时频率 $f_p[n]$ 随时间的均值进行估计, 此时的粗 CFO 可以由下式表示:

$$\Delta f_{\text{coarse}} = \frac{1}{L} \sum_{n=0}^{L-1} f_p[n] \quad (13)$$

所以对原始接收端的前导码信号 $r_p[n]$ 进行粗 CFO 补偿得到 $r'_p[n]$, 如下式所示:

$$r'_p[n] = r_p[n] \cdot e^{-j2\pi\Delta f_{\text{coarse}}nT_s} \quad (14)$$

精 CFO 补偿: 粗的 CFO 补偿并不足够准确, 补偿后仍有一些残余的 CFO。因此, 需要采取一种精细的 CFO 估计方式进行进一步的 CFO 补偿, 补偿公式如下式:

$$\widehat{\Delta f_{\text{coarse}}} = -\frac{1}{2\pi T_s} \angle \left(\sum_n^{L-1} r'_p[n] \cdot r'^{*}_p[n+L] \right) \quad (14)$$

其中 $\angle$ 计算的复数的角度, 式中主要体现的仍是一个自相关的思想, 通过计算前导码中重复结构在接收端的相似程度判断存在的残余 CFO, 进一步 $r[n]$ 经过精 CFO 补偿得到 $r'[n]$, 如下式所示:

$$r''_p[n] = r'_p[n] \cdot e^{-j2\pi\widehat{\Delta f_{\text{fine}}}nT_s} \quad (15)$$

4) 归一化

信号强度的差异被视为硬件损伤特征之一, 但是其受发射机功率和通信距离的影响很大, 通常不能直接被用来设备识别, 可使用相应的归一化方法消除其影响。




图 14 各过程的时频图




图 15 预处理后的前导码

3.3 基于相位差分特征的指纹识别模型

该模型是本项目的核心模型，是基于相位差分特征的 LoRa 设备识别方法。利用连续双帧的指纹特性，提取相位噪声和 CFO，通过差分操作生成相位差分

特征，消减信道影响，并综合考虑相位差分特征和 CFO 对分类的影响，再结合机器学习算法设计混合特征分类器，从而实现设备识别。

(1) 整体框架

设备识别方法 Diff-ADF 分为两个阶段，即注册阶段和识别阶段，其框架如 4-4-2 图所示。

注册：LoRa 设备分组发送帧，每组由连续双帧组成。USRP 是用于捕捉原始 LoRa 无线电信号。在捕获射频信号后，根据 3.2.3 节所述进行数据预处理，包括同步、CFO 估计、CFO 补偿和幅度归一化等操作，然后通过计算得到相位差分特征。同时，在射频指纹数据库中加入 CFO 和相位差分特征。最后，根据数据库得出各设备的特征参考值。

识别：与注册阶段的操作类似，LoRa 设备发送连续双帧，通过信号处理和特征提取获得 CFO 和相位差分特征。首先，利用射频指纹数据库中 CFO 与 CFO 参考值的比较进行辅助识别。然后，计算相位差分特征与标签参考值之间的均方误差，并选择最接近的值。




图 16 Diff-ADF 框架

(2) 相位差分特征提取

相位噪声提取公式如下式所示：

$$\varphi = \angle\left(\frac{1}{L} \sum_{n=1}^L s[n] \cdot z^*[n]\right) \quad (16)$$

其中 $z^*[n]$ 是接收机生成的理想信号在 $z[n]$ 的共轭。

由于信道的影响，不同帧的相位噪声有较大的波动。因此提取的相位噪声可以表示为：

$$\varphi = \varphi_{pi} + \varphi_{ch} \quad (16)$$

其中 φ_{pi} 为发射机物理损伤引起的相位偏移， φ_{ch} 为信道效应。

由于前导持续时间通常很短，可以假设在前导期间信道对符号相位具有相同的影响。

为了消除信道效应影响，本项目使用了最大最小归一化对相位噪声进行归一化处理，如下式所示：

$$\hat{\varphi} = \frac{\varphi - \varphi_{min}}{\varphi_{max} - \varphi_{min}} \quad (17)$$

其中 φ_{max} 和 φ_{min} 分别为相位噪声的最大值和最小值。

设备开始传输帧后，信号在达到稳态之前会经历瞬态、半稳态。然后，瞬态非常短暂，存在于信号的开始。半稳态也很快结束，这在 LoRa 设备的前导中有所体现。一般情况下，LoRa 设备工作在正常传输模式下，传输帧之间有一定的时间间隔。在这些间隔期间，设备进入休眠模式，导致每个帧的前导反映半稳定状态。为了捕捉稳态前导信号，本项目使用连续双帧传输模式，其中第二帧在第一帧之后立即发送，而不过休眠模式。




图 17 连续双帧的相位噪声及其差分特征（SC_1,250 对连续双帧）




图 18 连续双帧的相位噪声及其差分特征（SC_3,250 对连续双帧）

本项目使用同一型号的两个设备，即 RA01-SC 进行实验。这两个设备分别被称为 SC_1 和 SC_3。前导中的符号数设置为默认值 8。实验为每个设备收集了 250 对连续双帧，并提取了它们的相位噪声。图 4-4-3 和图 4-4-4 分别描绘了不同顺序帧的归一化相位噪声和两种器件的相位差分特征的密度图。从图 4-4-3 b 和图 4-4-4 b 可以看出，稳态时相位噪声指纹的区分度不够。从图 4-4-3 a 和图 4-4-4 a 可以看出，第一帧的特征是不稳定的。因此，本文尝试使用差分方法来获得更稳定和独特的指纹。归一化后的前导相位噪声记为 $\hat{\varphi}_i^j$ ，其中 j 表示连续双帧中的第一帧/第二帧，i 表示对应的前导符号。相位差分特征如下式所示：

$$\Delta\Phi = [\hat{\varphi}_0^1 - \hat{\varphi}_0^2, \hat{\varphi}_1^1 - \hat{\varphi}_1^2, \dots, \hat{\varphi}_7^1 - \hat{\varphi}_7^2] = [\Delta\hat{\varphi}_0, \Delta\hat{\varphi}_1, \dots, \Delta\hat{\varphi}_7] \quad (18)$$

图 4-4-3 c 和图 4-4-4 c 为两个设备的相位差分特征密度图。可以观察到，SC_1 和 SC_3 可以清晰区分，数据点的范围比单帧更窄。因此，相位差分特征具有区分度和稳定性。连续双帧的相位差分特征原理如图 4-4-5 所示。




图 19 连续双帧的相位差分特征

(3) Diff-ADF 分类器

相位差分特征是一种有效的指纹。然而，对于同一型号的设备，它们的硬件损伤可能非常相似。如果仅仅根据相位差分特征来判断，可能会得到错误的结果。

CFO 会随着晶振温度的变化而变化，但其总体波动保持在一定范围内。本项目将连续双帧的 CFO 作为二维特征存储在数据库中。这里 CFO 虽然不适合作为主要特征，但可以起到辅助设备识别的作用。

本项目设计混合特征分类器 Diff-ADF，它使用相位差分特征和 CFO 进行识别，如算法 1 所示。具体地，首先建立射频指纹数据库 $\mathcal{F} = \{(\Delta\Phi_i, \Delta\hat{\varphi}_i^1, \Delta\hat{\varphi}_i^2) | i \in [1, n]\}$ ，其中每个元组代表一个设备，n 为设备总数， $\Delta\Phi$ 为

相位差分特征的参考值, $\Delta\hat{f}^1$ 为第一个帧的 CFO 参考值, $\Delta\hat{f}^2$ 为第二个帧的 CFO 参考值。对于要识别的设备, 算法需要遍历数据库中的每个标签, 并将提取的指纹与每个标签的参考值进行比较。首先, 提取连续双帧的 CFO, x_1 和 x_2 , 然后计算它们到标签的参考 CFO 值的距离。由于温度会引起 CFO 的漂移, 算法为 CFO 设置了一个阈值 λ 。只有当距离超过 λ 时, 算法才能得出结论, 要识别的设备不太可能与相应的标签相关联。然后, 提取相位差分特征, 并计算其均方误差与标签的参考值。最后, 选择均方误差最小的标签。

算法 1 Diff-ADF

输入: 射频指纹数据库 $\mathcal{F}$; CFO 阈值 λ ; 从待识别设备上提取的特征, 即第一个帧的 CFO x_1 , 第二个帧的 CFO x_2 和相位差分特征 y

输出: 预测的标签 d

1. **for each tuple** $(\Delta\Phi_i, \Delta\hat{f}_i^1, \Delta\hat{f}_i^2)$ **in** $\mathcal{F}$ **do**
2. **if** $|x_1 - \Delta\hat{f}_i^1| \leq \lambda$ **and** $|x_2 - \Delta\hat{f}_i^2| \leq \lambda$ **then**
3. $D_i \leftarrow (y - \Delta\Phi_i)^2$
4. **else**
5. $D_i \leftarrow +\infty$
6. **end if**
7. **end for**
8. $d \leftarrow \arg\min_i (D_i)$
9. **return** d




图 20 模型代码截图

3.4 实验验证

(1) Diff-ADF 实验结果

为验证该模型的设别识别能力，本项目不仅收集了与训练集同一天的测试集，还收集了与训练集不同日期的测试集。在收集训练集一周后，本论文收集了测试集。测试集和训练集来自不同天的设备识别结果如图所示。当测试集和训练集来自不同天时，准确率为 65.67%。此外，当测试集与训练集在同一天收集时，准确率为 90.22%。




图 21 Diff-ADF 测试集和训练集来自同一天




图 22 Diff-ADF 测试集和训练集来自不同天

(2) 基于深度学习的模型实验结果

SC-RFFI（可扩展且信道鲁棒的射频指纹识别）是一种基于深度学习的射频指纹识别技术，旨在解决传统方法依赖人工特征提取和现有深度学习方案缺乏可扩展性与信道鲁棒性的问题。该技术通过短时傅里叶变换（STFT）将 LoRa 信号转换为频谱图，并利用相邻频谱列相除消除信道干扰，保留硬件损伤特征，构建信道无关的时频图作为输入。其核心是采用深度度量学习框架训练 RFF 提取器，通过三元组损失函数生成 512 维设备唯一指纹，而非直接分类模型，从而具备泛化能力以支持未知设备。系统分为训练、注册和认证三个阶段：训练时利用第三方大数据集增强信道多样性；注册时提取合法设备指纹存入数据库，实现动态设备管理；认证时结合 k-NN 算法进行恶意设备检测与身份分类。SC-RFFI 突破了设备位置变化的限制，支持物联网设备快速接入与退出，在低功耗场景下为设备身份认证提供了无需硬件修改的高效安全方案。

实验结果：




图 23 SC-RFFI 测试集和训练集来自同一天




图 24 SC-RFFI 测试集和训练集来自不同天

(3) 比较与总结




图 25 Diff-ADF 和 SC-RFFI 的结果比较

本项目实现了一种基于连续双帧相位差分特征的 LoRa 设备识别模型（Diff-ADF），并复现了基于深度学习的信道鲁棒性 LoRa 射频指纹识别模型（SC-RFFI），以进行对比分析。整体而言，模型实现较为成功，在测试集与训练集来自同一天的情况下，均取得了较高的准确率。

在测试集与训练集来自不同天的情况下，尽管整体准确率尚未完全达到预期，但值得注意的是，本项目基于特征工程的方法明显优于 SC-RFFI 模型。这一结果表明，Diff-ADF 在信道变化的环境下展现出更强的鲁棒性和稳定性，验证了该方法在 LoRa 设备识别任务中的优越性。

4.项目后期研究方案

4.1 模型完善优化方案

当前射频指纹识别模型尚未完成对非视距（NLoS）环境、低信噪比（SNR）条件、信道动态特性以及连续帧操作特征提取方面的系统性评估与测试，并且

仍存在着一定程度上的鲁棒性与准确性不足的问题。为了系统地评估并提升模型性能，我们提出并将实施以下模型优化方案：

（1）数据采集优化方案

进行多环境、多场景数据扩充，在 LoS 与 NLoS 条件下进行充分的数据采集，特别注重不同材料障碍物（如混凝土墙、金属板、木质材料）对信号传播的影响。扩展信噪比范围测试（从 16 dB 降低至 5 dB），详细记录不同 SNR 条件下的识别准确率变化，提高模型在极端低信噪比条件下的鲁棒性。收集来自多个不同设备、多位置、多时间段的数据，避免模型过拟合于特定环境或特定设备。

（2）数据预处理优化方案

1) 噪声抑制与多径效应补偿

使用自适应噪声抑制技术（如 Kalman 滤波）去除环境噪声，提高信号清晰度采用经验模态分解（EMD）和小波变换有效去除随机噪声，确保指纹特征的稳定性。通过拉格朗日插值技术校准多径效应引起的时延误差，进一步提高特征质量。

2) 信道归一化与 CFO 校正

实施信道估计与均衡技术，有效消除信道条件变化对信号特征提取的影响。优化载波频率偏移（CFO）补偿方案，引入温度-频率漂移建模，实现更准确的补偿。采用傅里叶变换（FFT）实现精确的相位标准化和频率漂移校正。

（3）特征提取优化方案

1) 扩展特征维度与时频分析

引入短时傅里叶变换（STFT）以提取更加丰富的动态时频特征，提升模型的分辨能力。利用 EMD 提取信号细节，提高信号特征的稳定性与辨识度。

2) 探索更具有鲁棒性泛化性的特征

深度学习分析 LoRa 设备及其物理层信息，综合分析差分、拼接、相加等连续帧操作对识别效果的影响，通过消融实验确定最佳操作方式。

（4）模型结构优化方案

1) 轻量级时序深度学习模型

结合 1D-CNN 与 GRU/LSTM 混合模型结构，捕捉信道动态特征变化，提高对环境变化的适应能力。增加注意力机制（Self-Attention），突出识别关键特征，进一步提升对微弱变化的敏感性。




图 26 轻量级学习模型架构示例

2) 度量学习强化泛化性

使用 Siamese Network 或 Triplet Loss 进行度量学习，强化模型对不同设备特征差异的区分能力，提升泛化性能。

4.2 实验规模扩大方案

目前我们已完成 18 台型号为 RA01-SC、搭载 LLCC68 芯片的设备的数据采集并进行实验。这批设备表现稳定，实验结果的准确率和鲁棒性较为不错，已基本满足小规模实验的需求。在此基础上，我们初步验证了系统架构的可行性以及关键算法的有效性，为后续的大规模实验奠定了技术基础。

随着项目的深入推进，实验需求将逐步扩大。我们计划引入更多型号（如 RA02、RA08 等）和更大量级（预估 60 台以上）的终端设备，以覆盖更大范围、更复杂环境下的数据采集任务。为更好的进行数据处理和模型结构问题查找和优化工作，以及为更之后的模型泛化性的提升做好基础。

我们预计的实验设备如下表所示：

表 1 实验规模方案表

设别型号	芯片	数量
RA01-SC	LLCC68	18
Dragino SX127x Shield	SX127x	10

Heltec LoRa32	SX1262	15
Heltec Cube Cell	SX1262	15
Ebyte EoRa S3	SX1268	10

4.3 泛化性水平提升方案

为提升 LoRa 射频指纹识别模型在不同时间、设备、环境下的适应能力与鲁棒性，我们提出以下方案：

（1）抗遗忘能力增强

引入弹性权重保护（EWC）机制，避免新设备学习时覆盖原有知识。建立关键样本缓存库（Replay），每类设备保留代表性 CFO 与相位差分特征用于混合训练。

（2）快速适应新设备/时间

采用局部微调机制，新样本仅更新分类器或 Adapter 模块，主干参数保持稳定。同时在推理阶段引入主模型+微调模型融合预测，提升新类识别的同时维持旧类准确性。

（3）存储与计算优化

使用 Attention-PCA 对设备指纹进行压缩，仅保存关键特征主成分，减少内存与计算开销。结合样本选择策略，提升数据代表性与模型泛化能力。

5.经费使用记录

表 2 项目经费使用记录表

名称	数量	总价
LoRa 模块 Ra-01SC	2	38.4
LoRa 模块 EoRa-S3-400TB	2	178.06